

Pasivno zamijenjena: cijena inflacije koju ne mjeri indeks potrošačkih cijena

Od inflacijskog vala do dezinflacije: institucionalni jaz u pažnji HNB-a 2021.–2026.

Petra Palić
Luka Sikić

Sažetak

Vraća li se relativna medijska vidljivost središnje banke nakon smirivanja inflacijskog vala? Na hrvatskom korpusu digitalnih objava od 2021. do 2026. ponovno procjenjujemo vezu inflacije i institucionalnog jaza u pažnji HNB-a. Primarni uzorak obuhvaća 270 uporabljivih tjedana, odnosno 268 opažanja u regresiji nakon oblikovanja promjena inflacije unutar neprekinutih segmenata. Porast inflacije za jedan postotni bod povezan je s povećanjem jaza za 0,00210 jedinica uz kontrolu obujma objava, odnosno 0,00132 bez te kontrole. Unutar novog izvora podataka jaz raste i pri kontroli razine inflacije; pozitivan trend ostaje prisutan u korpusu zajedničkih izvora. Veći nagib u kasnijem razdoblju nije robustan na kontrolu vremenskih trendova. Ispravno usmjerene lokalne projekcije ne potvrđuju raniju tvrdnju o postojanom predviđanju očekivanja: nalazi ovise o interpolaciji anketne serije i skupu kontrola. Istodobno, usporedba s HANFA-om i provjere instrumenata ograničavaju uzročno tumačenje. Nalazi podupiru praćenje relativne medijske zastupljenosti kao zasebne dimenzije institucionalne komunikacije, ali ne dokazuju da njezin pad uzrokuje neusidrena očekivanja.

Ključne riječi: institucionalni jaz u pažnji; HNB; inflacija; dezinflacija; medijska vidljivost; očekivanja potrošača.

1. Uvod

Pad inflacije ne mora vratiti središnjoj banci prostor koji je prethodno izgubila u medijskom diskursu. U hrvatskim digitalnim medijima stoga ispituje dva povezana, ali različita pitanja: prati li relativna zastupljenost HNB-a kretanje inflacije te vraća li se prema početnoj razini nakon završetka inflacijskog vala. Proširenje razdoblja opažanja omogućuje odvojeno promatranje rasta cijena, uvođenja eura i kasnijeg razdoblja znatno manje varijabilnosti inflacije. Međutim, promjena izvora medijskih podataka podudara se s početkom toga kasnijeg razdoblja. Razliku razina preko toga prijeloma zato ne možemo pripisati samo ekonomskom režimu.

Institucionalna komunikacija dolazi do javnosti kroz urednički odabir, naslove, citate i raspodjelu prostora među temama. Objavljena poruka i poruka koju publika može susresti nisu ista empirijska veličina. Mediji mogu opširno izvještavati o cijenama hrane, troškovima energije ili državnim intervencijama, dok središnja banka istodobno zauzima manji udio toga diskursa. Literatura o ograničenoj obradi informacija objašnjava zašto sama dostupnost monetarnog signala ne jamči njegovo uključivanje u očekivanja (Mankiw i Reis, 2002; Sims, 2003). Literatura o medijskom odabiru pokazuje da je zastupljenost institucije rezultat organizacijskih odluka i konkurencije među sadržajima (Shoemaker i Vos, 2009).

Rad povezuje te probleme mjerom institucionalnog jaza u pažnji (Institutional Attention Gap, IAG). Ona označava razliku između fiksnog početnog udjela HNB-a i njegova trenutačnog udjela u diskursu o inflaciji, uz ponderiranje objava istaknutošću i potencijalnim dosegom. Riječ je o pokazatelju relativne zastupljenosti u praćenom korpusu. Pokazatelj ne mjeri izravno čitanost, povjerenje ili razumijevanje monetarne politike, niti njegova početna vrijednost određuje društveno optimalnu razinu pažnje. Izraz

cijena inflacije u naslovu metafora je promjene relativne zastupljenosti; ne označava procijenjeni novčani trošak ili gubitak blagostanja.

Nastavljamo prethodnu analizu razdoblja do kraja 2023. godine, ali ponovno provjeravamo i njezinu numeričku i interpretacijsku osnovu. Glavni doprinos proširenja nije samo dulja vremenska serija. Uspoređujemo nagibe unutar izvora, uvodimo korpus zajedničkih izvora i izvornih objava, a dinamiku računamo bez povezivanja opažanja preko tekstualne praznine. Time razdvajamo povezanost inflacije i relativne zastupljenosti od promjene sastava korpusa. Dodatno ispravljamo opis sentimenta, identitet prehrambenog instrumenta i vremenski smjer lokalnih projekcija.

Rezultati zadržavaju pozitivan uvjetni nagib inflacije, ali sužavaju ranije zaključke o mehanizmu. U kasnijem razdoblju jaz nastavlja rasti unutar istog izvora. Doprinos proširenja jest dokumentiranje pada relativne institucionalne zastupljenosti unutar faze prikupljanja s nižom inflacijom, uz izričitu kontrolu mjernih prijeloma. Samo centriranje udjela u odnosu na početnu bazu ne dodaje novu informaciju o monetarnom mehanizmu. Nema robusnog dokaza da je inflacijski nagib postao veći, da je mrežna centralnost trajno erodirala ili da medijski jaz stabilno predviđa očekivanja kućanstava. U nastavku razvijamo teorijska očekivanja, objašnjavamo konstrukciju podataka, prikazujemo rezultate i razmatramo granice njihove interpretacije.

2. Teorijski okvir

2.1 Očekivanja i ograničena pažnja

U standardnom novokeynesijanskom okviru inflacija ovisi o očekivanoj budućoj inflaciji, proizvodnom jazu i troškovnim šokovima (Woodford, 2003). Polazišna Phillipsova krivulja glasi:

$$\pi_t = \beta E_t[\pi_{t+1}] + \kappa x_t + u_t.$$

Oznaka x_t predstavlja proizvodni jaz, u_t troškovni šok, a parametri β i κ određuju težine očekivanja i realne aktivnosti. Komunikacija je važna jer može utjecati na informacije iz kojih privatni sektor oblikuje očekivanja. Ipak, ta jednadžba sama ne opisuje tko institucionalnu poruku susreće, koliko je razumije i kojoj joj važnosti pridaje.

Racionalna nepažnja polazi od ograničenog kapaciteta obrade informacija (Sims, 2003). Ljepljive informacije dodatno dopuštaju da se skup informacija obnavlja neredovito (Mankiw i Reis, 2002). Monetarni signal stoga možemo povezati s raspodjelom pažnje općim zapisom:

$$E_t[\pi_{t+1}] = f(S_t, \mathcal{A}_t).$$

Oznaka S_t predstavlja sadržaj signala, a $\mathcal{A}_t$ pažnju usmjerenu prema njemu. Ovaj zapis nije procijenjeni model očekivanja. Njegova je svrha odvojiti sadržaj poruke od mogućnosti da poruka uđe u informacijski skup kućanstva. Eksperimentalni radovi o monetarnoj komunikaciji pokazuju da je reakcija očekivanja kućanstava zaseban empirijski problem, a ne automatska posljedica objave priopćenja (Coibion i sur., 2022).

2.2 Medijsko posredovanje institucionalnog signala

Medijski odabir pretvara institucionalnu komunikaciju u vijest. Tema, naslov, položaj citata i sugovornici određuju na što će objava usmjeriti pozornost. Teorija gatekeepinga naglašava organizacijski odabir

sadržaja, a teorija uokvirivanja značenje koje proizlazi iz njegova predstavljanja (Entman, 1993; Shoemaker i Vos, 2009). Filtrirani signal zapisujemo kao:

$$\tilde{S}_t = g(CB_t, M_t, C_t),$$

gdje CB_t predstavlja komunikacijsku aktivnost središnje banke, M_t strukturu medijskog prostora, a C_t konkurentski diskurs. Očekivanja se zatim mogu povezati s filtriranim signalom:

$$E_t[\pi_{t+1}] = h(\tilde{S}_t).$$

Iz ovih zapisa ne slijedi da manji udio institucije nužno pogoršava očekivanja. Publika može dobiti pouzdanu informaciju od drugih aktera, a institucionalna se poruka može prenositi bez izričitog imenovanja HNB-a. Empirijski test zato mora odvojeno obuhvatiti medijski udio, njegovu povezanost s inflacijom i vremensku vezu s očekivanjima.

2.3 Institucionalni jaz i njegovo mjerenje

Konceptualni jaz između referentne zastupljenosti i opažene vidljivosti označavamo izrazom:

$$IAG_t = R_t - V_t.$$

U empirijskom dijelu R_t zamjenjujemo fiksnim početnim udjelom. To je mjerilo promjene, a ne procjena normativne odgovornosti. Pozitivan jaz znači da je ponderirani udio niži od vlastite baze; negativan jaz znači da je viši. Ni jedno predznačenje samo po sebi ne utvrđuje kvalitetu komunikacije.

Vezu s monetarnom transmisijom ilustrira zapis iz početnog teorijskog okvira:

$$\pi_t = \beta E_t[(1 - \phi IAG_t)\pi_{t+1}] + \kappa x_t + u_t.$$

Mogući slijed utjecaja prikazuje se kao:

$$u_t \rightarrow \tilde{S}_t \rightarrow E_t[\pi_{t+1}].$$

Ove odnose ne izvodimo kao strukturnu ravnotežu niti procjenjujemo parametar ϕ . Zapis s prigušenjem naslijeđena je heuristika, a ne model u koji se empirijski IAG može izravno uvrstiti: promjena proizvoljne početne baze promijenila bi njegovu razinu bez promjene opaženih udjela. Iz njega zato ne izvodimo testiranu strukturnu predikciju ni tvrdnju o usidrenosti očekivanja. Jednadžbe služe motivaciji zasebnih empirijskih provjera, a ne pretvaranju deskriptivnog pokazatelja u identificirani monetarni mehanizam.

2.4 Ekstenzivna i intenzivna margina

Relativna zastupljenost može pasti zato što se objavljuje manje relevantnih tekstova o HNB-u ili zato što ti tekstovi nose slabiji signal i manji potencijalni doseg. Prvi pomak pratimo ekstenzivnom marginom, odnosno omjerom broja relevantnih objava o HNB-u i broja objava inflacijskog korpusa. Drugi pratimo intenzivnom marginom, koja uspoređuje ponderirani doseg po relevantnoj objavi o HNB-u s dosegom po objavi u nazivniku. Zbog korekcija nazivnika i razlika u ponderiranju njihov umnožak nije stroga računovodstvena dekompozicija primarnog jaza.

Broj objava nije broj kontakata pojedinca s porukom. Jedan se tekst može prenijeti na više portala, dok procjena dosega ne razlikuje istu osobu koja je poruku susrela više puta. Zato uz osnovni pokazatelj procjenjujemo varijantu samo izvornih objava te varijante s drukčijim ponderima dosega i istaknutosti. One provjeravaju osjetljivost mjere na konstrukcijske odluke.

2.5 Pažnja ovisna o režimu i postojanost tijekom dezinflacije

Pažnja prema inflaciji može se mijenjati nelinearno. Bracha i Tang dokumentiraju da je nepažnja izraženija pri nižoj inflaciji, dok Pfäuti modelira prijelaz prema većoj pažnji kada inflacija prijeđe prag (Bracha i Tang, 2019; Pfäuti, 2023). Ti nalazi motiviraju provjeru promjene nagiba, ali ne određuju prag za Hrvatsku niti jamče da pažnja prema cijenama povećava pažnju prema središnjoj banci. Ta se dva oblika pažnje mogu kretati u suprotnim smjerovima.

Iskustvo s inflacijom također može djelovati dulje od samoga šoka. Učenje iz osobnog iskustva povezuje prethodno proživljene stope inflacije s kasnijim očekivanjima (Malmendier i Nagel, 2016). U medijskom prostoru analogna bi se postojanost mogla pojaviti kroz zadržavanje tema, izvora i uredničkih rutina. Ovdje je tretiramo kao hipotezu. Ako jaz raste unutar istoga izvora i nakon kontrole inflacije, takav je nalaz sukladan nepotpunom oporavku vidljivosti. Za dokaz histereze trebalo bi utvrditi da povijest šoka mijenja buduće stanje i nakon isključivanja drugih trajnih promjena, što ovaj uzorak ne omogućuje.

3. Podaci i empirijska strategija

3.1 Korpus, obuhvat i prekidi

Analiza se temelji na već izrađenim mjesečnim i tjednim agregatima hrvatskoga medijskog korpusa. Brojnik obuhvaća objave prepoznate formalnim nazivom HNB-a, kraticom te oblicima izraza središnja i centralna banka. Inflacijska relevantnost određena je tekstualnim pravilima i pripadnošću inflacijskom korpusu. Generički nazivi mogu obuhvatiti i druge središnje banke; mjera je stoga vezana uz operativnu definiciju korpusa, a ne uz savršenu identifikaciju svake objave o HNB-u.

Zadržavamo platforme iz početne analize. Naknadno dodani televizija, radio, tisak i nove društvene platforme nisu uključeni u glavni korpus jer različita dostupnost dosega u brojniku i nazivniku narušava usporedivost. Izvorne članke koristimo samo za agregirane provjere zajedničkih izvora, sindikacije, mreže i dosega. Članci i osobni metapodaci ostaju izvan izlaznih materijala.

Tablica 1 prikazuje veličinu korpusa po razdobljima. Prikaz uključuje i razdoblja koja ne ulaze u glavne regresije; time obuhvat baze razlikujemo od analitičkog uzorka.

Tablica 1: Obuhvat mjesečnog korpusa po razdobljima

Razdoblje	Mjeseci	Objave	Relevantne objave	Uporabljivi mjeseci
Prije eura	24	40.386	21.080	24
Euro / stari izvor	12	18.062	11.928	12
Tekstualna praznina	3	581	285	0
Novi izvor	30	37.328	20.507	28

Od travnja 2024. godine baza prelazi na širi izvoz dobavljača. Promjena je obilježena varijablom BATCH_NEW. U prvom tromjesečju iste godine nedostaje tekst za većinu objava; neuporabljive mjeseci i tjedne isključujemo prema oznakama kvalitete. Završna nepotpuna razdoblja također ne ulaze u glavni uzorak. Tjedan s početkom na Novu godinu zadržan je u primarnom tjednom uzorku jer ima potpun tekst i prolazi unaprijed definirani filter kvalitete. Zato granica prvoga neprekinutog tjednog segmenta nije posve jednaka kalendarskoj granici mjesečnog segmenta.

Sentiment NEG udio je dobavljačevih oznaka $\text{AUTO_SENTIMENT} == \text{negative}$ među označenim relevantnim objavama. Ne potječe iz lokalno validiranog modela XLM-RoBERTa; raniji opis takve validacije ne prenosimo. Od lipnja 2026. dobavljačeve oznake postaju pretežno neutralne. Glavne analize zato završavaju u svibnju, a proširenje kroz srpanj služi samo provjeri osjetljivosti.

3.2 Konstrukcija pokazatelja i vanjske serije

Ponderirani udio HNB-a računa se iz inflacijski relevantnih objava $\mathcal{H}_t$ i inflacijskog korpusa $\mathcal{J}_t$:

$$s_t = \frac{\sum_{i \in \mathcal{H}_t} w_i \text{REACH}_i}{\sum_{j \in \mathcal{J}_t} \text{REACH}_j + 1}, \quad \text{IAG}_t = \bar{s} - s_t.$$

Ponder w_i kombinira prisutnost u naslovu, položaj prvoga spominjanja, rang relativne učestalosti spominjanja i jezične oznake institucionalnog djelovanja. Doseg je dobavljačeva procjena potencijalne publike, uz imputaciju nedostajućih vrijednosti u korpusu HNB-a. Početni udio $\bar{s}$ računa se zasebno po frekvenciji u prvih 6 mjeseci početne godine, uz pravilo uklanjanja ekstremnih početnih udjela iz postojeće izgradnje podataka. Mjesečna baza iznosi 0,04026, a tjedna 0,03869.

Vanjske serije obuhvaćaju hrvatsku HICP inflaciju, prehrambenu i energetska HICP inflaciju europodručja te bilancu očekivanja potrošača iz ankete Europske komisije. Inflacija i mrežna centralnost u tjednim su podatcima mjesečne veličine pridružene mjesecu početka tjedna. Veći broj redaka stoga ne znači jednak porast broja neovisnih makroekonomskih opažanja. Anketna bilanca opisuje očekivani smjer cijena, a ne izravno dugoročnu usidrenost očekivanja. Anketnu bilancu prikazujemo mjesečno te uz linearnu i stepenastu interpolaciju na tjednoj frekvenciji.

Za alternativni instrument preuzimamo nominalni FAO Food Price Index i računamo njegovu godišnju promjenu (Food and Agriculture Organization of the United Nations, 2026). Ranija varijabla nazvana FAO indeksom zapravo je Eurostatov prehrambeni pokazatelj; te serije ne poistovjećujemo. Google Trends koristimo kao deskriptivnu kontrolu, uz standardizaciju unutar izvornih prozora preuzimanja. Definicije glavnih varijabli sažima tablica 2.

Tablica 2: Varijable i granice njihova tumačenja

Varijabla	Definicija
IAG_primary	Početni minus tekući ponderirani udio HNB-a
IAG_ext	Omjer broja relevantnih objava HNB-a i inflacijskog korpusa
IAG_int	Relativni ponderirani doseg po objavi
C_EV	Svojstvena centralnost HNB-a u projekciji mreže izvora i aktera
pi_t; d_pi	Godišnja HICP inflacija i promjena unutar segmenta
HHI_all	Koncentracija dosega izvora u korpusu HNB-a
NEG	Udio negativnih oznaka dobavljača
log_vol	Logaritam broja svih objava korpusa HNB-a uvećanog za jedan
exp_balance	Bilanca anketnih odgovora o budućem kretanju cijena
BATCH_NEW	Pokazatelj novog izvoza od promjene izvora

Varijabla obujma odnosi se na objave korpusa HNB-a, a ne na cjelokupni inflacijski diskurs. Ta je razlika važna za interpretaciju: kontrola za $\log_vol$ može uklanjati varijaciju koja je dio samog mjerenja

institucionalne prisutnosti. Razliku koeficijenata s tom kontrolom i bez nje zato ne nazivamo identificiranim posredovanim učinkom.

3.3 Uzorci i segmenti

Uzorak S0 čuva početno razdoblje usporedbe. S1 je primarni uzorak uporabljivih razdoblja prije promjene sentimenta. S3 obuhvaća samo novi izvor prije te promjene, a S2 proširuje provjeru osjetljivosti kroz srpanj završne godine. Za sve glavne zaključke usporedno prikazujemo S0, S1 i S3. Tablica 3 razlikuje dostupne periode i potpuna opažanja osnovne regresije.

Tablica 3: Uzorci i stvarni broj opažanja

Frekvencija	Uzorak	Dostupno	U regresiji	Početak	Kraj
Mjesečno	S0	36	35	2021-01-01	2023-12-01
Mjesečno	S1	62	60	2021-01-01	2026-05-01
Mjesečno	S2	64	62	2021-01-01	2026-07-01
Mjesečno	S3	26	25	2024-04-01	2026-05-01
Tjedno	S0	157	156	2020-12-28	2023-12-25
Tjedno	S1	270	268	2021-01-04	2026-05-25
Tjedno	S2	279	277	2021-01-04	2026-07-27
Tjedno	S3	113	112	2024-04-01	2026-05-25

Pomake i prethodne vrijednosti oblikujemo unutar neprekinutih segmenata. Prva promjena inflacije u svakom segmentu zato nedostaje. U tjednom S1 ostaje 268 regresijskih opažanja, a u mjesečnom 60. Pomak unaprijed također mora ostati unutar istoga segmenta: projekcija prije tekstualne praznine ne koristi očekivanja nakon nje. Jednako pravilo vrijedi za blokove u simulacijama i za kovarijance reziduala u HAC procjeni.

Deskriptivne statistike u tablici 4 pokazuju da novi segment donosi drukčiju raspodjelu inflacije, a ne ponavljanje istoga inflacijskog ciklusa. Razlike prosječne razine medijskih pokazatelja preko promjene izvoza ne tumačimo kao strukturne ekonomske učinke.

Tablica 4: Mjesečni prosjeci i standardne devijacije unutar primarnog uzorka

Varijabla	Prije eura	Euro / stari izvor	Novi izvor
IAG_primary	0,004 (0,012)	-0,007 (0,039)	0,017 (0,010)
IAG_ext	0,145 (0,046)	0,131 (0,021)	0,113 (0,024)
IAG_int	0,257 (0,061)	0,364 (0,315)	0,200 (0,068)
C_EV	0,900 (0,173)	0,962 (0,055)	0,876 (0,261)
pi_t	6,662 (4,629)	8,467 (2,211)	4,192 (0,599)
NEG	0,691 (0,078)	0,637 (0,047)	0,609 (0,064)
HHI_all	0,106 (0,045)	0,170 (0,060)	0,088 (0,043)

3.4 Specifikacija i inferencija

Procjenjujemo model bez kontrole obujma i model s tom kontrolom:

$$IAG_t = \alpha + \beta\pi_t + \gamma\Delta\pi_t + \delta EURO_t + \theta HHI_t + \eta NEG_t + \lambda BATCH_t + \varepsilon_t,$$

$$IAG_t = \alpha + \beta\pi_t + \gamma\Delta\pi_t + \delta EURO_t + \theta HHI_t + \eta NEG_t + \rho \log V_t + \lambda BATCH_t + \varepsilon_t.$$

Unutar pojedinoga segmenta izostavljamo indikatore koji su konstantni. Parametar β predstavlja uvjetnu povezanost inflacije i jaza. Za Newey–Westovu korekciju koristimo Bartlettove težine i širinu pojasa $[N^{1/3}]$, bez prethodnog izbjeljivanja (Newey i West, 1987). Kod združenih segmenata ne računamo međusegmentne umnoške reziduala. Dodatno prikazujemo grupiranje po mjesecima, alternativne širine pojasa, izostavljanje pojedinih mjeseci i simulacijsku inferenciju.

Instrumentalne varijable služe provjeri osjetljivosti na endogenost, uz izričitu pretpostavku isključenja. Prehrambena i energetska inflacija europodručja mogu biti snažno povezane s hrvatskom inflacijom, ali mogu izravno utjecati i na temu medijskih objava. Snažan prvi stupanj zato nije dovoljan za uzročno tumačenje. Tu prijetnju provjeravamo regresijama za HANFA-u i testom preidentificirajućih ograničenja.

Za lokalne projekcije (Jordà, 2005) koristimo ispravno usmjerene buduće vrijednosti anketne bilance:

$$E_{t+h} = a_h + b_h IAG_t + c'_h Z_t + u_{t+h}, \quad h \geq 0.$$

Osnovni skup kontrola obuhvaća inflaciju, njezinu promjenu, sentiment, euro i promjenu izvora gdje su indikatori relevantni. Proširena specifikacija dodaje prethodno očekivanje i prethodnu marginu, koncentraciju i obujam. Bonferronijeva korekcija obuhvaća svih 13 unaprijed zadanih horizonata unutar svake obitelji uzorka, frekvencije, pokazatelja i interpolacije. To ne uklanja višestruko testiranje između različitih obitelji, pa izdvojene značajne horizonte tumačimo oprezno.

4. Rezultati

Rezultate prikazujemo od kontinuiteta osnovne procjene prema marginama, dinamici i očekivanjima. Zatim ispitujemo režime, mrežnu strukturu, HANFA-u i osjetljivost zaključaka. Takav redoslijed razlikuje ponovljivost koeficijenta od dokaza o mehanizmu koji bi ga mogao proizvesti.

4.1 Kontinuitet i ispravci početne analize

Tjedni koeficijent uz inflaciju u S0 iznosi 0,002024, nasuprot 0,00201 iz sažetka početnog rada. Relativna razlika iznosi 0,70 posto. Međutim, njegova spremljena glavna tablica navodi 0,00213, pa početni sažetak i tablica nisu međusobno numerički sukladni. Potpuna usporedba prijavljenih glavnih koeficijenata i margina nalazi se u popratnom dodatku. Strogo podudaranje zaokruženih vrijednosti nije potvrđeno. U postojećoj validaciji dokumentirane su promjene imputiranog dosega, rangova i aktivnih izvora; dodatno izvještavamo dijagnostiku granice tjednog razdoblja. Sve razlike ne možemo pripisati samo jednom uzroku.

Tablica 5: Koeficijenti zamrznute glavne tablice i ponovno procijenjeni S0


Frekvencija	Objavljeno	S0	Stari N	N regresije
Mjesečno	0,00168	0,001648	36	35
Tjedno	0,00213	0,002024	157	156

Provjera također zahtijeva ispravak interpretacije. Navedeni izvorni koeficijent pripada specifikaciji s kontrolom obujma. Kod lokalnih projekcija u početnoj implementaciji kombinacija negativnog pomaka i naredbe za vodstvo vraćala je prošla, a ne buduća očekivanja. U nastavku sve projekcije koriste buduća očekivanja; usporedba oba smjera nalazi se u dodatku. Početne tvrdnje o prediktivnom kanalu zato ne smatramo potvrđenima samom reprodukcijom pogrešno usmjerenog izračuna.

4.2 Inflacija i obrazac relativnog istiskivanja

Na primarnom tjednom uzorku koeficijent uz inflaciju iznosi 0,00210 uz $p < 0,001$. Interval pouzdanosti proteže se od 0,00113 do 0,00307. Pri nepromijenjenim ostalim regresorima porast inflacije s 2 na 10 posto odgovara razlici predviđenog jaza od 0,0168 jedinica. To je uvjetni scenarij unutar procijenjenog modela, a ne procjena učinka monetarne intervencije.

Slika 1 prikazuje putanje osnovnih veličina. Praznina u linijama označava neuporabljive mjesece, dok okomite crte upozoravaju na euro, promjenu izvora i promjenu sentimenta. Povećanje jaza preko promjene izvora ne može se odvojiti od promjene mjerenja samo na temelju ove slike.



Slika 1: Mjesečne putanje jaza, inflacije, centralnosti i koncentracije

Tablica 6 uspoređuje sve glavne uzorke i obje specifikacije. Pozitivan koeficijent pojavljuje se na obje frekvencije. U modelu bez kontrole obujma tjedni koeficijent iznosi 0,00132. Uključivanje obujma povećava njegovu vrijednost. Razlika specifikacija, prema tome, ne podupire tvrdnju da opaženi obujam posreduje unaprijed određen udio učinka inflacije.


Tablica 6: Koeficijenti inflacije bez kontrole i s kontrolom obujma

Frekvencija	Uzorak	N	Bez obujma	S obujmom
Mjesečno	S0	35	0,00105 (0,00074)	0,00165** (0,00074)
Mjesečno	S1	60	0,00128* (0,00065)	0,00175*** (0,00061)

Frekvencija	Uzorak	N	Bez obujma	S obujmom
Mjesečno	S3	25	0,00633*** (0,00203)	0,00650*** (0,00189)
Tjedno	S0	156	0,00117** (0,00047)	0,00202*** (0,00058)
Tjedno	S1	268	0,00132*** (0,00043)	0,00210*** (0,00049)
Tjedno	S3	112	0,00639*** (0,00240)	0,00723*** (0,00233)

Standardne pogreške nalaze se u zagradama. Zvezdice označavaju pragove $p < 0,10$ (*), $p < 0,05$ (**) i $p < 0,01$ (***); sve numeričke procjene i nekorigirane vrijednosti p dostupne su u tabličnim rezultatima analize. Njihovu interpretaciju nadopunjujemo provjerama vremenske ovisnosti i konstrukcije korpusa.

Slika 2 prikazuje prosjeke po razredima inflacije i režimima. To je deskriptivni prikaz, bez uklanjanja utjecaja kontrolnih varijabli. Intervali oko prosjeka služe prikazu raspršenosti i ne zamjenjuju HAC inferenciju iz regresija.



Slika 2: Prosječni tjedni jaz po razredima inflacije i režimima

4.3 Broj objava i intenzitet signala


Koeficijent inflacije uz ekstenzivnu marginu u S1 iznosi -0,00707, a uz intenzivnu -0,00359. Za razliku od primarnog jaza, veća vrijednost tih margina znači veću relativnu prisutnost HNB-a. Negativan koeficijent ekstenzivne margine zato je sukladan smanjenju udjela relevantnih objava pri višoj inflaciji. Tablica 7 prikazuje i rezultate za centralnost kako bi se razlike među ishodima procjenjivale na istim uzorcima.

Tablica 7: Inflacija i margine relativne zastupljenosti

Frekvencija	Uzorak	Centralnost	Ekstenzivna	Intenzivna
Mjesečno	S0	0,00438 (0,00496)	-0,00475** (0,00178)	-0,00489 (0,00530)

Frekvencija	Uzorak	Centralnost	Ekstenzivna	Intenzivna
Mjesečno	S1	0,00236 (0,00547)	-0,00533*** (0,00161)	-0,00471 (0,00447)
Mjesečno	S3	-0,15818 (0,10523)	-0,01637** (0,00737)	-0,03281* (0,01747)
Tjedno	S0	0,00227 (0,00354)	-0,00680*** (0,00136)	-0,00306 (0,00376)
Tjedno	S1	0,00054 (0,00415)	-0,00707*** (0,00141)	-0,00359 (0,00335)
Tjedno	S3	-0,10176 (0,06659)	-0,02105*** (0,00633)	-0,02574* (0,01464)

Rezultati nisu dovoljni za tvrdnju da cjelokupno istiskivanje djeluje isključivo preko broja objava. Intenzivna margina sadrži i salijentnost i doseg, a obje margine dijele dio nazivnika. U dodatku zato uspoređujemo standardizirane koeficijente zajedničkim blokovnim bootstrapom. Slika 3 prikazuje da se promjene broja i intenziteta relevantnih objava ne odvijaju uvijek usporedno.




Slika 3: Ekstenzivna i intenzivna margina tijekom primarnog razdoblja

4.4 Dinamika i lokalna nestabilnost

Model korekcije odstupanja procjenjujemo zasebno u početnom i novom segmentu. U tjednim podacima koeficijent uz prethodno odstupanje od procijenjenog odnosa iznosi -1,030 u S0 te -0,676 u S3. Negativan koeficijent opisuje povratno kretanje nakon odstupanja, ali sam po sebi ne dokazuje kointegraciju ni strukturnu brzinu prilagodbe.

Testovi granica (Pesaran i sur., 2001) daju različitu potporu odnosu među razinama ovisno o frekvenciji i segmentu. Za mjesečni S3 vrijednost p iznosi 0,605. Kratak segment i mala varijabilnost inflacije ograničavaju pouzdanost dugoročnog tumačenja. Nadalje, inflacija i mrežne veličine u tjednim podacima nisu izvorno tjedne serije. Rezultate korekcije odstupanja zato prikazujemo kao opis dinamike uz dijagnostiku, a ne kao samostalan dokaz ravnotežnog mehanizma.

Slika 4 prikazuje lokalne procjene iz mjesečnih prozora koji ne prelaze podatkovnu prazninu. Promjene nagiba mogu odražavati i malu lokalnu varijaciju regresora. Točkasti intervali na slici nisu zajednička traka pouzdanosti; simultana korekcija dostupna je uz spremljene rezultate.



Slika 4: Pomične procjene koeficijenta inflacije unutar neprekinutih segmenata


4.5 Očekivanja nakon ispravka smjera projekcija

U osnovnoj specifikaciji s linearnom interpolacijom nijedan budući tjedni horizont u S0 ni u S1 ne prolazi Bonferronijevu korekciju. U S1 ostaje značajna istodobna povezanost, ali ona nije dokaz predviđanja budućih očekivanja. Stepnasta interpolacija daje značajne kratke horizonte u S1, dok mjesečni podatci izdvajaju udaljeni horizont. Tablica 8 prikazuje sve osnovne obitelji i ne izostavlja te iznimke.

Tablica 8: Budući horizonti ekstenzivne margine nakon Bonferronijeve korekcije

Frekvencija	Uzorak	Seriya	Horizonti	Značajni horizonti	Najmanji korigirani p
Mjesečno	S0	Mjesečna bilanca	12	12	0,005
Mjesečno	S1	Mjesečna bilanca	12	12	0,003
Mjesečno	S3	Mjesečna bilanca	12	Nijedan	0,149
Tjedno	S0	Linearna	12	Nijedan	0,823
Tjedno	S0	Stepnasta	12	Nijedan	0,240
Tjedno	S1	Linearna	12	Nijedan	0,092
Tjedno	S1	Stepnasta	12	1, 2	0,016
Tjedno	S3	Linearna	12	Nijedan	0,087
Tjedno	S3	Stepnasta	12	1	0,020

Slika 5 uspoređuje S0 i S1 pod istom specifikacijom i korekcijom. Linearna interpolacija unaprijed raspoređuje informaciju iz susjednih mjesečnih anketa, pa se takve projekcije ne mogu čitati kao prognoze dostupne u stvarnom vremenu. Stepenasta serija uklanja taj oblik zaglađivanja, ali ponavlja istu mjesečnu informaciju kroz više tjedana. Rezultate stoga provjeravamo i u izvornim mjesečnim podacima.



Slika 5: Tjedne lokalne projekcije s istodobnim Bonferronijevim intervalima unutar obitelji

Dodavanje prethodnih očekivanja i prethodne margine mijenja obrazac značajnosti, uključujući pojavu značajnih kratkih horizonata pri linearnoj interpolaciji. Taj rezultat prikazujemo u dodatku, ali ne koristimo ga za zamjenu unaprijed zadane osnovne specifikacije. Zajedno, nalazi upućuju na osjetljivost prediktivne veze na način vremenskog razvrstavanja anketne informacije i na uvjetovanje prethodnim očekivanjima. Tvrdnja o postojanom kanalu od medijske zastupljenosti prema budućim očekivanjima nije robusno potvrđena.

4.6 Uvođenje eura, novi režim i dezinflacija

Koeficijent inflacije u tjednom S3 iznosi 0,00723, što je brojčano više nego u S0. Međutim, izravna usporedba dviju zasebnih procjena zanemaruje razlike u varijanci inflacije i u kontrolama. Interakcija inflacije i novoga izvora u združenom modelu daje $p = 0,091$; nakon dodavanja trendova vrijednost iznosi 0,754. Tablica 9 prikazuje i kontrolu godišnjih učinaka. Ne zaključujemo da je inflacijski nagib postao veći.

Tablica 9: Razlika inflacijskog nagiba novog i starog izvora uz alternativne kontrole


Frekvencija	Kontrola	Razlika nagiba	p
Mjesečno	Bez dodatka	-0,00145 (0,00316)	0,648
Mjesečno	Trendovi	-0,00313 (0,00308)	0,315
Mjesečno	Godine	-0,00290 (0,00450)	0,522
Tjedno	Bez dodatka	0,00410* (0,00242)	0,091

Frekvencija	Kontrola	Razlika nagiba	p
Tjedno	Trendovi	0,00092 (0,00294)	0,754
Tjedno	Godine	0,00271 (0,00310)	0,383

Istodobno, mjesečni jaz unutar S3 raste za 0,00076 jedinica po mjesecu nakon kontrole inflacije i ostalih regresora, uz $p = 0,001$. U korpusu zajedničkih izvora trend iznosi 0,00056, uz $p = 0,045$. Taj nalaz nastaje unutar iste faze izvoza i podupire tvrdnju o nepotpunom oporavku relativne zastupljenosti. Ne isključuje promjene intenziteta praćenja ili sastava objava unutar zadržanih izvora.

Odvojene procjene za rast i pad inflacije te pretraga praga daju dodatne provjere. Bootstrap koji ponavlja cijelu pretragu čvora daje tjedni $p = 0,115$. Stoga izbor najboljega čvora nije dokaz postojanja ekonomskog praga. Rezultati testova prijeloma, asimetrije i praga prikazani su u dodatku; promjenu povezanu s novim izvorom ondje izričito označavamo kao podatkovno i ekonomski isprepletenu.

Slika 6 prikazuje procijenjeni doprinos odstupanja inflacije od početnog prosjeka, uz ostale regresore zadržane na opaženim vrijednostima. Bootstrap blokove oblikujemo unutar segmenata. Scenarij odgovara na pitanje kako se predikcija modela mijenja kada se promijeni samo inflacija; ne uključuje moguću prilagodbu sentimenta, obujma ili ponašanja medija.




Slika 6: Uvjetna razlika predviđenog jaza prema scenariju početne inflacije

4.7 Mrežna struktura i obujam

Pad prosječne centralnosti u kasnijim godinama nije dovoljan dokaz strukturne erozije. Promjena skupa izvora utječe na mrežu, a svojstvena centralnost normalizira položaj HNB-a prema ostalim akterima u svakom mjesecu. Nadalje, niz može sadržavati pojedinačne mjesece s izrazito drukčijom mrežnom strukturom. Zato uz izvornu mjeru rekonstruiramo mrežu iz tekstova i provjeravamo isti skup zajedničkih izvora.

Slika 7 uspoređuje te putanje samo unutar kasnijeg razdoblja. Rekonstrukciju provjeravamo prema izvornom panelu prije tumačenja zajedničke mreže. Korelacija rekonstruirane i izvorne mjesečne centralnosti iznosi 1,0000, a najveća apsolutna razlika 0,0003. Preostalu razliku ne tretiramo kao ekonomski nalaz.



Slika 7: Izvorna, rekonstruirana i zajednička mrežna centralnost unutar novog razdoblja

Koeficijent mjesečnog trenda centralnosti zajedničkih izvora iznosi -0,00509, uz $p = 0,187$. Taj nalaz, zajedno s provjerom rekonstrukcije, ne opravdava opću tvrdnju da se relativni jaz nakon promjene izvora pretvorio u trajni gubitak mrežne središnjosti. Relativni udio i mrežni položaj opisuju različite dimenzije komunikacijskog prostora.

4.8 HANFA i granice institucionalno specifičnog tumačenja


HANFA omogućuje usporedbu s drugom institucijom prisutnom u istom korpusu. No njezin jaz nije konstruiran potpuno istovjetno: brojnik koristi doseg objava o HANFA-i bez iste HNB-ove salijentnosti i filtra relevantnosti. Zajednički izvor i nazivnik zato ne jamče da se učinak promjene izvora poništava oduzimanjem. Razliku HNB–HANFA tretiramo kao provjeru, a ne kao automatski očišćenu mjeru.

U tjednom S1 HANFA-in koeficijent inflacije iznosi 0,00398, uz $p = 0,014$. Koeficijent razlike između institucija nije statistički razlučiv od nule u istom uzorku. Tablica 10 i slika 8 pokazuju zašto HANFA ne može služiti kao čista negativna kontrola koja bi potvrdila specifičnost HNB-ova mehanizma.

Tablica 10: Inflacijski nagib HANFA-e i razlike HNB–HANFA

Frekvencija	Uzorak	HANFA	HNB – HANFA
Mjesečno	S0	0,00230 (0,00157)	-0,00065 (0,00211)
Mjesečno	S1	0,00196 (0,00154)	-0,00021 (0,00198)
Mjesečno	S3	-0,00439 (0,00424)	0,01089** (0,00445)

Frekvencija	Uzorak	HANFA	HNB – HANFA
Tjedno	S0	0,00435** (0,00169)	-0,00232 (0,00193)
Tjedno	S1	0,00398** (0,00160)	-0,00188 (0,00186)
Tjedno	S3	-0,00303 (0,00383)	0,01026*** (0,00379)



Slika 8: Mjesečni jaz HNB-a i HANFA-e prema njihovim vlastitim bazama

U modelu razlike koeficijent nakon uvođenja eura može se prikazati kao uvjetna razlika promjena među institucijama. Takva procjena nije identificirani učinak eura bez pretpostavke paralelnih putanja i usporedive izloženosti drugim promjenama. Posebno zabrinjava što eurozonski instrumenti predviđaju HANFA-in jaz i nakon kontrole hrvatske inflacije: zajednički test u tjednom S1 daje $p = 0,007$. To ne određuje točan oblik povrede isključenja za HNB, ali oslabljuje tvrdnju da instrumenti djeluju isključivo preko hrvatske inflacije.

4.9 Robusnost i registar tvrdnji

Pozitivan tjedni nagib opstaje pri različitim HAC širinama, grupiranju po mjesecima i izostavljanju pojedinih mjeseci. Blokovna permutacija u S1 daje $p = 0,004$, a fazno preslagivanje $p = 0,013$. Mjesečna simulacijska inferencija slabija je od osnovne HAC inferencije. Takva razlika potvrđuje potrebu za izvještavanjem više postupaka, umjesto odabira onoga koji daje najmanju vrijednost p .

Specifikacijska krivulja obuhvaća različite definicije jaza, koncentracije i kontrola. Za primarni pokazatelj svi tjedni nagibi u S1 pozitivni su, a isto vrijedi za varijante zajedničkih izvora i izvornih objava. Unutarnja mjera salijentnosti ima drukčiji nazivnik i ne daje jednako stabilan predznak. Broj pozitivnih procjena zato ne tumačimo kao broj neovisnih potvrda iste hipoteze. Tablica 11 sažima zaključke koji proizlaze iz tih provjera.

Tablica 11: Registar glavnih tvrdnji prema obnovljenim rezultatima

Tvrdnja	Status
Pozitivan nagib inflacije	Pozitivna asocijacija u svim uzorcima
Rast jaza unutar novog izvora	Podržana asocijacija
Veći učinak nakon promjene izvora	Nije robusno podržano
Trajno predviđanje očekivanja	Ovisi o interpolaciji i specifikaciji
Strukturna erozija centralnosti	Nije potvrđena
Uzročno istiskivanje samo HNB-a	Dijagnostika slabi identifikaciju

5. Rasprava

Najstabilniji nalaz rada jest povezanost više inflacije s manjim relativnim udjelom institucionalnog signala. On je prisutan u početnom razdoblju i u proširenom uzorku te nije ograničen na jednu operacionalizaciju dosega. Ipak, preciznost nagiba ovisi o vremenskim kontrolama: tjedni model s godišnjim indikatorima i mjesečni model s odvojenim trendovima ne odbacuju nulti nagib. Istodobno, kontrola broja HNB-ovih objava povećava nagib inflacije, pa se prethodno objašnjenje preko unaprijed kvantificiranoga volumenskog posredovanja ne može zadržati. Rezultati pokazuju da je način uvjetovanja obujmom dio ekonomskog pitanja, a ne tehnički detalj regresije.

Rast jaza unutar kasnijega razdoblja dodatno sugerira da dezinflacija nije popraćena automatskim oporavkom relativne medijske zastupljenosti. Taj se obrazac pojavljuje i nakon ograničenja na zajedničke izvore. Moguća su različita objašnjenja: trajna promjena uredničkih tema, veći interes za druge institucije, promjena oblika prenošenja monetarnih poruka ili intenziteta praćenja izvora. Bez podataka o uredničkim odlukama i stvarnoj izloženosti publike ne možemo odrediti njihove relativne doprinose. Nalaz je sukladan postojanosti medijskih obrazaca, ali nije dokaz histereze u strukturnom smislu.

Literatura o pažnji ovisnoj o inflaciji usmjerava pozornost prema promjeni važnosti informacija za kućanstva (Bracha i Tang, 2019; Pfäuti, 2023). Naši rezultati dopunjuju to pitanje razlikovanjem pažnje prema cijenama i pažnje prema središnjoj banci. Veći interes za inflaciju ne mora povećati udio HNB-a u tematskom prostoru. Ipak, podaci o medijskim objavama ne dopuštaju prijelaz s te razlike na tvrdnju o tome kako pojedinci obrađuju informacije. Za taj bi prijelaz trebalo povezati objave s individualnom izloženošću i anketnim odgovorima.

Ispravak vremenskog smjera lokalnih projekcija posebno mijenja interpretaciju očekivanja. Povezanost današnje medijske zastupljenosti s prošlim očekivanjima može odražavati reakciju medija na već formiran interes javnosti. Ona ne dokazuje da zastupljenost predviđa buduća očekivanja. Ispravno usmjerene projekcije otkrivaju rezultate koji ovise o interpolaciji i dinamici kontrola, pa ne podupiru jednostavan prijenos od institucionalnog jaza prema anketnoj bilanci. Uzajamni utjecaj medija i javnosti ostaje otvoreno pitanje.

Za institucionalnu komunikaciju nalaz opravdava zajedničko praćenje broja priopćenja, relativnog udjela relevantnih objava i kvalitete prenošenja poruke. Povećanje broja vlastitih objava ne jamči veći relativni udio u diskursu koji se širi ili mijenja temu. Međutim, iz ovih podataka ne proizlazi da bi veći udio HNB-a sam po sebi poboljšao očekivanja. Takvu bi tvrdnju trebalo provjeriti eksperimentom ili istraživanjem koje vjerodostojno odvaja izloženost poruci od prethodnog interesa za inflaciju.

Ograničenja su konkretna. Promjena izvoza ostaje vremenski isprepletena s ekonomskim režimom; isti naziv izvora ne jamči nepromijenjen obuhvat njegovih objava. Doseg mjeri potencijalnu publiku i različito je dostupan u korpusima. Generički izrazi za središnju banku mogu pogrešno uključiti objave o drugim institucijama. Dobavljačev sentiment nema prikazanu neovisnu validaciju na ovome korpusu. Tjedna frekvencija ponavlja mjesečne makroekonomske podatke, a kasniji segment sadrži malo varijacije inflacije. HANFA i instrumenti ne daju dovoljno uvjerljivo isključenje zajedničkih medijskih šokova. Budući rad treba stabilnu specifikaciju izvoza, ručno označen uzorak tekstova te podatke o stvarnom kontaktu publike s institucionalnim porukama.

6. Zaključak

Prošireni hrvatski uzorak zadržava pozitivan odnos inflacije i institucionalnog jaza u pažnji HNB-a, uvjetno na operativnu definiciju korpusa. Viša inflacija povezana je s manjim ponderiranim udjelom relevantnih institucionalnih objava. Unutar novog izvora relativni udio nastavlja padati i nakon kontrole inflacije, uključujući korpus zajedničkih izvora. Taj opisni nalaz ne određuje je li se udio vratio na početnu razinu preko promjene izvoza.

Proširenje istodobno ograničava mehanističke zaključke. Veći kasniji nagib nije robustan na trendove, strukturna erozija mrežne centralnosti nije potvrđena, a očekivanja ne pokazuju stabilan prediktivni odnos kroz različite prikaze anketne serije. Provjere HANFA-e i instrumenata dodatno nalažu asocijativno, a ne bezuvjetno uzročno tumačenje.

Institucionalna vidljivost stoga zaslužuje mjerenje kao poseban ishod komunikacije. Njezinu ulogu u oblikovanju očekivanja tek treba identificirati dizajnom koji povezuje medijsku poruku, izloženost pojedinca i naknadnu promjenu njegovih uvjerenja.

Metodološki dodatci

A1 Konstrukcija korpusa i sentiment

Identifikacija HNB-ovih objava koristi hrvatske morfološke oblike naziva institucije, kraticu te generičke nazive središnje banke. Inflacijska relevantnost kombinira ključne riječi i pripadnost inflacijskom korpusu. Te definicije zadržavamo radi kontinuiteta. One zahtijevaju neovisnu provjeru preciznosti i odziva na ručno označenom uzorku prije zaključivanja o potpunom institucionalnom obuhvatu.

Oznaka sentimenta preuzeta je od dobavljača. Nisu provedeni ni XLM-RoBERTa klasifikacija ni ranije opisano međumodelsko validiranje. Udio negativnih oznaka stoga je operativna kontrola čija promjena može nastati i promjenom postupka dobavljača. Isključivanje završnog razdoblja iz S1 sprječava izravno združivanje neusporedivih oznaka, ali ne uklanja moguću pogrešku klasifikacije prije prijeloma.

A2 Istaknutost, doseg i sindikacija

Salijentnost objave računa se kao $w_i = 0,30T_i + 0,25P_i + 0,20F_i + 0,25S_i$. Komponente označavaju naslov, relativni položaj, rang učestalosti spominjanja i jezičnu oznaku djelovanja. Imputacija dosega koristi dostupne medijane po izvoru i duljini teksta, zatim medijanu izvora i ukupnu medijanu. Granice winsorizacije i rangovi računaju se na cijelom proširenom korpusu, što objašnjava male promjene ranijeg dijela serije.

Varijanta samo izvornih objava uklanja zapise označene kao indicirane iz HNB-ova brojnika. Nazivnik ostaje glavni inflacijski korpus. Zato to nije potpuno deduplicirana mjera cijelog tematskog prostora, nego provjera osjetljivosti institucionalnog brojnika na prenošenje tekstova. Varijanta samo opaženog dosega i jednaki salijentni ponderi daju sljedeće nagibe.

Tablica 12: Osjetljivost na opaženi doseg i jednake pondere istaknutosti u S1

Frekvencija	Varijanta	Koeficijent
Mjesečno	Opaženi doseg	0,00177*** (0,00061)
Mjesečno	Jednaki ponderi	0,00182*** (0,00064)
Tjedno	Opaženi doseg	0,00212*** (0,00049)
Tjedno	Jednaki ponderi	0,00220*** (0,00051)

A3 Specifikacijska krivulja i početna baza

Specifikacije kombiniraju definicije ishoda, koncentracije i kontrola na istim unaprijed zadanim uzorcima. Alternativna fiksna baza mijenja samo presjek modela koji sadrži konstantu; identični nagibi nisu neovisna provjera ekonomskog mehanizma. Varijanta unutarnje salijentnosti mjeri drugu veličinu jer ne koristi isti inflacijski nazivnik.

Tablica 13: Predznaci i značajnost specifikacija na tjednom S1

Varijanta	Broj	Pozitivni	Negativni	p < 0,05
IAG_primary	9	9	0	9
IAG_monpol	9	9	0	9
IAG_all	9	9	0	9
IAG_full	9	9	0	1
IAG_winsor	9	9	0	9
IAG_within	9	6	3	0
IAG_common	9	9	0	9
IAG_orig	9	9	0	6

A4 Permutacijska inferencija

Permutacije primjenjujemo na rezidualne ograničenog modela bez inflacijskog regresora, uz ostale kontrole zadržane. Blokovo preslagivanje i randomizacija Fourierovih faza provode se odvojeno po neprekinutim segmentima. Svaki postupak koristi 1000 ponavljanja i korekciju brojnika i nazivnika vrijednosti p . To su uvjetni simulacijski testovi, a ne egzaktna randomizacijska inferencija iz nasumično dodijeljenog tretmana.

Tablica 14: Blokove i fazne permutacije koeficijenta inflacije

Frekvencija	Uzorak	Postupak	p
Mjesečno	S0	Blokovi	0,128
Mjesečno	S0	Faze	0,146

Frekvencija	Uzorak	Postupak	p
Mjesečno	S1	Blokovi	0,065
Mjesečno	S1	Faze	0,074
Mjesečno	S3	Blokovi	0,059
Mjesečno	S3	Faze	0,033
Tjedno	S0	Blokovi	0,004
Tjedno	S0	Faze	0,048
Tjedno	S1	Blokovi	0,004
Tjedno	S1	Faze	0,013
Tjedno	S3	Blokovi	0,014
Tjedno	S3	Faze	0,046

A5 Korekcija odstupanja i test granica

Rezidual prethodno procijenjenog odnosa među razinama ulazi u regresiju prve razlike jaza uz promjene kontrola i prethodnu promjenu jaza. Pogreške prvoga koraka nisu potpuno obuhvaćene standardnom HAC pogreškom drugoga koraka, pa prikazane vrijednosti služe opisnoj procjeni dinamike. Odvojeno procijenjena pozitivna i negativna odstupanja te testovi jediničnog korijena spremljeni su uz rezultate.

Tablica 15: Koeficijenti korekcije odstupanja po segmentima

Frekvencija	Uzorak	N	Korekcija odstupanja
Mjesečno	S0	33	-1,14877*** (0,30725)
Mjesečno	S3	23	-0,91598*** (0,19583)
Tjedno	S0	154	-1,02994*** (0,10013)
Tjedno	S3	110	-0,67641*** (0,10579)

Test granica koristi unaprijed određen autoregresijski raspored s prethodnom vrijednošću ishoda i sadašnjim i prethodnim vrijednostima inflacije, koncentracije, sentimenta i obujma. Kritične vrijednosti simuliraju se za veličinu segmenta. Ti testovi ne rješavaju problem kratkog uzorka, mogućih stacionarnih omjera i različite izvorne frekvencije varijabli.

Tablica 16: Test granica po frekvencijama i segmentima

Frekvencija	Uzorak	N	F	p
Mjesečno	S0	35	7,645	0,003
Mjesečno	S3	25	1,763	0,605
Tjedno	S0	156	36,675	<0,001
Tjedno	S3	112	10,812	<0,001

A6 Instrumentalne varijable i prvi stupanj

Osnovna IV procjena instrumentira razinu hrvatske inflacije eurozonskom prehrambenom i energetsom inflacijom. Promjena hrvatske inflacije tretira se kao uključena egzogena kontrola; to je dodatna

pretpostavka, osobito ako su razina i promjena zahvaćene istim šokom. Procjene stoga označavamo kao IV osjetljivost, bez automatskog uzročnog statusa.

Tablica 17: IV procjene s eurozonskim prehrambenim i energetskim instrumentima

Frekvencija	Uzorak	N	IV koeficijent	p
Mjesečno	S0	35	0,00134* (0,00078)	0,097
Mjesečno	S1	60	0,00152** (0,00067)	0,027
Mjesečno	S3	25	0,00411 (0,00267)	0,140
Tjedno	S0	156	0,00187*** (0,00057)	0,001
Tjedno	S1	268	0,00191*** (0,00052)	<0,001
Tjedno	S3	112	0,00485* (0,00260)	0,065

Prikazujemo klasični parcijalni F i HAC Waldovu statistiku podijeljenu brojem isključenih instrumenata. Potonju ne poistovjećujemo s formalnim efektivnim F-testom sa zasebnim kritičnim vrijednostima za slabe instrumente.

Tablica 18: Relevancija instrumenata po uzorcima

Frekvencija	Uzorak	Klasični F	HAC Wald / k	Parcijalni R ²
Mjesečno	S0	239,5	210,6	0,947
Mjesečno	S1	432,6	212,5	0,944
Mjesečno	S3	23,8	91,9	0,726
Tjedno	S0	1.504,1	430,3	0,953
Tjedno	S1	2.436,3	391,3	0,950
Tjedno	S3	130,5	224,2	0,713

A7 Preidentificirajuća ograničenja i Anderson–Rubinov skup

J-test temelji se na drugom koraku linearne GMM procjene s kovariancom momenata korigiranom unutar segmenata. Neodbacivanje zajedničkih ograničenja ne dokazuje valjanost svakog instrumenta. Rezultate posebno uspoređujemo s izravnom prediktivnošću instrumenata za HANFA-u.

Tablica 19: HAC GMM test preidentificirajućih ograničenja

Frekvencija	Uzorak	J	p
Mjesečno	S0	2,486	0,115
Mjesečno	S1	0,664	0,415
Mjesečno	S3	3,461	0,063
Tjedno	S0	0,121	0,728
Tjedno	S1	0,513	0,474
Tjedno	S3	4,219	0,040

Za S3 invertiramo HAC Anderson–Rubinov test na širokoj mreži mogućih koeficijenata. Nijedna točka pretražene mreže nije prihvaćena ni na jednoj frekvenciji. To nije uski interval procjene niti dokaz da je

koeficijent jednak nuli; upućuje na moguću nesukladnost instrumenata i ograničenja modela. Pretraga diskretne mreže također ne dokazuje da je cijeli kontinuirani skup prazan. Tablica prikazuje broj prihvaćenih točaka i najveću vrijednost p .

Tablica 20: Raspon prihvaćenih Anderson–Rubinovih vrijednosti u S3

Frekvencija	Prihvaćenih	Najveći p	Donja	Gornja
Mjesečno	0	0,006	Nijedna točka	Nijedna točka
Tjedno	0	0,019	Nijedna točka	Nijedna točka

A8 Stvarni FAO instrument

Godišnja promjena nominalnog FFPI-ja zamjenjuje eurozonske instrumente u zasebnoj procjeni. Izvorni CSV i zapis preuzimanja omogućuju provjeru identiteta serije. Globalne cijene hrane također mogu izravno promijeniti medijsko izvještavanje; drugačiji izvor podataka sam po sebi ne otklanja problem isključenja.

Tablica 21: Alternativni IV s godišnjom promjenom stvarnog FAO indeksa

Frekvencija	Uzorak	Koeficijent
Mjesečno	S0	0,00315*** (0,00056)
Mjesečno	S1	0,00334*** (0,00062)
Mjesečno	S3	-0,01907 (0,02290)
Tjedno	S0	0,00272*** (0,00100)
Tjedno	S1	0,00253*** (0,00084)
Tjedno	S3	0,00289 (0,01123)

A9 Prve razlike i zaostala inflacija

Prve razlike uklanjaju stalne razine segmenata, ali mijenjaju pitanje s odnosa među razinama na kratkoročno zajedničko kretanje. Inflacija iz drugoga prethodnog razdoblja služi dodatnoj provjeri vremenske strukture; zbog postojanosti inflacije njezin koeficijent nije čisti placebo eksperiment. Prvi zaostatak ne može se zasebno identificirati uz sadašnju inflaciju i njezinu prvu razliku jer je njihova linearna kombinacija.

Tablica 22: Regresije u prvim razlikama

Frekvencija	Uzorak	N	Prve razlike
Mjesečno	S0	35	0,00758 (0,00488)
Mjesečno	S1	60	0,00847 (0,00508)
Mjesečno	S3	25	0,00616* (0,00329)
Tjedno	S0	156	-0,00121 (0,00968)
Tjedno	S1	268	-0,00050 (0,00741)
Tjedno	S3	112	0,01248** (0,00620)

Tablica 23: Zaostala inflacija uz sadašnju inflaciju i kontrole

Frekvencija	Uzorak	Zaostala inflacija
Mjesečno	S0	-0,00143 (0,00469)
Mjesečno	S1	-0,00115 (0,00361)
Mjesečno	S3	-0,00233 (0,00365)
Tjedno	S0	-0,00044 (0,00455)
Tjedno	S1	-0,00138 (0,00391)
Tjedno	S3	-0,00810 (0,00569)

A10 Snaga i najmanji razlučivi pomak

MDE i približnu snagu računamo iz procijenjene HAC pogreške, uz fiksnu referentnu veličinu iz izvornoga tjednog sažetka. To je uvjetna usporedba preciznosti, a ne neovisna potvrda istinitosti opaženog koeficijenta. Posebno slabija preciznost S3 odražava malu varijaciju inflacije unutar kasnijeg segmenta.

Tablica 24: Preciznost i približna snaga za fiksni referentni koeficijent

Frekvencija	Uzorak	N	MDE (80%)	Snaga (%)
Mjesečno	S0	35	0,00213	75,0
Mjesečno	S1	60	0,00175	89,7
Mjesečno	S3	25	0,00554	15,3
Tjedno	S0	156	0,00163	93,2
Tjedno	S1	268	0,00139	98,2
Tjedno	S3	112	0,00658	13,4

A11 Revizija smjera lokalnih projekcija

Izvorni poziv `shift(n = -h, type = "lead")` vraća zaostatak. To se može provjeriti na bilo kojem rastućem nizu: vrijednost uz današnji redak tada pripada prethodnom razdoblju. Donja usporedba zadržava isti S0, iste kontrole i izvorni skup horizonata te mijenja samo smjer pomaka. Ona dijagnosticira implementaciju; ne zamjenjuje glavne projekcije s unaprijed zadanim punim skupom horizonata.

Tablica 25: Ista lokalna regresija s budućim i prošlim očekivanjima

Horizont	Smjer	Koeficijent	Korigirani p
0	Prema budućnosti	-38,79	0,285
0	Prema prošlosti	-38,79	0,285
2	Prema budućnosti	-29,56	1,000
2	Prema prošlosti	-49,08	0,042
4	Prema budućnosti	-21,74	1,000
4	Prema prošlosti	-51,64	0,016
6	Prema budućnosti	-17,25	1,000

Horizont	Smjer	Koeficijent	Korigirani p
6	Prema prošlosti	-50,84	0,013
8	Prema budućnosti	-13,05	1,000
8	Prema prošlosti	-44,53	0,020
10	Prema budućnosti	-8,11	1,000
10	Prema prošlosti	-41,15	0,015
12	Prema budućnosti	-6,89	1,000
12	Prema prošlosti	-36,35	0,033

A12 Dodatne kontrole u projekcijama očekivanja

Proširena specifikacija uvjetuje na prethodnoj anketnoj bilanci, prethodnoj margini, koncentraciji i obujmu. Pojava ili nestanak značajnih horizonata pokazuje da osnovna i proširena specifikacija ne mjere jednaku uvjetnu vezu. Posebice se rezultati linearne interpolacije ne mogu koristiti kao prognoze s povijesno raspoloživim informacijama.

Tablica 26: Značajni budući horizonti u proširenoj LP specifikaciji

Frekvencija	Uzorak	Seriya	Značajni horizonti
Mjesečno	S0	Mjesečna bilanca	3, 8, 12
Mjesečno	S1	Mjesečna bilanca	Nijedan
Mjesečno	S3	Mjesečna bilanca	6, 7
Tjedno	S0	Linearna	1, 2, 3, 4, 5, 6, 7, 8, 9
Tjedno	S0	Stepenasta	4, 5, 6, 8, 9, 11
Tjedno	S1	Linearna	1, 2, 3, 4
Tjedno	S1	Stepenasta	Nijedan
Tjedno	S3	Linearna	Nijedan
Tjedno	S3	Stepenasta	Nijedan

A13 Grupiranje po mjesecima i HAC širine

Grupiranje po mjesecima dopušta ovisnost tjednih reziduala unutar mjeseca, a vrijednosti p koriste broj mjeseci za stupnjeve slobode. Ono samo ne rješava ovisnost između susjednih mjeseci. Zato ga prikazujemo usporedno s kalendarski i segmentno određenom HAC korekcijom. Cijela mreža HAC širina spremljena je uz rezultate.

Tablica 27: Standardne pogreške grupirane po mjesecima

Frekvencija	Uzorak	Mjeseci	Koeficijent
Mjesečno	S0	35	0,00165** (0,00068)
Mjesečno	S1	60	0,00175*** (0,00055)
Mjesečno	S3	25	0,00650** (0,00302)
Tjedno	S0	36	0,00202*** (0,00060)

Frekvencija	Uzorak	Mjeseci	Koeficijent
Tjedno	S1	63	0,00210*** (0,00048)
Tjedno	S3	26	0,00723*** (0,00250)

A14 Izostavljanje mjeseca i kolinearnost

Izostavljanje pojedinog mjeseca provjerava ovisi li predznak koeficijenta o jednom lokalnom dijelu putanje. HAC pritom koristi stvarne kalendarske razmake preostalih redaka. Najveći faktor inflacije varijance prikazujemo zasebno, bez univerzalnog praga koji bi automatski prihvaćao ili odbacivao model.

Tablica 28: Raspon procjena pri izostavljanju pojedinih mjeseci

Frekvencija	Uzorak	Minimum	Maksimum	Najveći p
Mjesečno	S0	0,00137	0,00207	0,073
Mjesečno	S1	0,00153	0,00202	0,019
Mjesečno	S3	0,00473	0,00821	0,046
Tjedno	S0	0,00179	0,00249	0,002
Tjedno	S1	0,00188	0,00240	<0,001
Tjedno	S3	0,00580	0,00841	0,014

Tablica 29: Najveći VIF među regresorima osnovne specifikacije

Frekvencija	Uzorak	Najveći VIF
Mjesečno	S0	2,54
Mjesečno	S1	3,66
Mjesečno	S3	1,80
Tjedno	S0	1,43
Tjedno	S1	2,68
Tjedno	S3	1,18

A15 Osjetljivost na neopažene čimbenike

Prikazujemo aproksimaciju proporcionalne selekcije nadahnutu pristupom Oster (2019). Pretpostavljena veza opaženih i neopaženih čimbenika nije provjerljiva u ovom vremenskom nizu. Promjena broja objava može biti dio samog mehanizma ili mjerenja, pa dodavanje kontrola ne mora odgovarati uklanjanju pristranosti. Prilagođene nagibe zato ne nazivamo identificiranim uzročnim granicama.

Tablica 30: Približna osjetljivost pod pretpostavkom proporcionalne selekcije

Frekvencija	Uzorak	Prilagođeni nagib	Delta za nulu
Mjesečno	S0	0,00150	10,996
Mjesečno	S1	0,00156	9,256
Mjesečno	S3	0,00915	-2,456
Tjedno	S0	0,00218	-12,817

Frekvencija	Uzorak	Prilagođeni nagib	Delta za nulu
Tjedno	S1	0,00230	-10,668
Tjedno	S3	0,00771	-14,900

A16 Monte Carlo provjera

Simulacija pod nulom zadržava predikciju modela bez inflacije i dodaje autoregresijske rezidualne procijenjene zasebno po segmentima. Uspoređuje se parcijalni doprinos inflacije objašnjennoj varijanci. Koristimo 5000 simulacija. Rezultat ovisi o odabranom autoregresijskom modelu nule i ne provjerava sve moguće oblike vremenske ovisnosti.

Tablica 31: Monte Carlo provjera parcijalnog doprinosa inflacije

Frekvencija	Uzorak	Parcijalni R ²	p
Mjesečno	S0	0,067	0,160
Mjesečno	S1	0,073	0,076
Mjesečno	S3	0,167	0,080
Tjedno	S0	0,052	0,006
Tjedno	S1	0,050	0,002
Tjedno	S3	0,074	0,035

A17 Prijelomi, asimetrija i prag

HAC Waldovi testovi zajedničke promjene nagiba uspoređuju specifikacije s interakcijama. To su robusne inačice testa promjene koeficijenata, a ne klasični homoskedastični Chowovi testovi. Za prijelom novog izvora ne postoji vremenska varijacija koja bi zasebno identificirala promjenu izvoza i ekonomskog režima.

Tablica 32: Zajednički testovi promjene nagiba

Frekvencija	Prijelom	Wald	p
Mjesečno	EURO	8,61	0,126
Mjesečno	BATCH_NEW	11,32	0,045
Tjedno	EURO	17,17	0,004
Tjedno	BATCH_NEW	11,29	0,046

Pozitivne i negativne promjene inflacije ulaze kao zasebni regresori. Negativna promjena zadržava svoj predznak, pa se koeficijent uz nju mora tumačiti zajedno s negativnom vrijednošću regresora. Pretraga praga ponavlja se u svakom bootstrap uzorku, čime se uvažava činjenica da čvor nije bio unaprijed poznat.

Tablica 33: Odvojeni nagibi pozitivnih i negativnih promjena inflacije

Frekvencija	Uzorak	Rast	Pad	p razlike
Mjesečno	S0	-0,00135	0,04154	0,016
Mjesečno	S1	-0,00216	0,03284	0,030

Frekvencija	Uzorak	Rast	Pad	p razlike
Mjesečno	S3	0,01003	0,00240	0,645
Tjedno	S0	0,00634	-0,00637	0,100
Tjedno	S1	0,00826	-0,00429	0,114
Tjedno	S3	0,01301	0,00949	0,798

Tablica 34: Pretraga nelinearnoga čvora s bootstrap korekcijom

Frekvencija	Čvor	F	Bootstrap p
Mjesečno	3,00	2,04	0,394
Tjedno	3,00	6,11	0,115

A18 Uvjetne razlike među institucijama

Regresija razlike HNB–HANFA algebrailki opisuje diferencijalnu promjenu između institucija. Kod samo dvije institucije ne koristimo inferenciju s dvama institucijskim klasterima, nego vremensku HAC korekciju. Ne tvrdimo da su paralelne putanje potvrđene niti da HANFA predstavlja identičan kontrafaktual za HNB.

Tablica 35: Uvjetna diferencijalna promjena oko eura i promjene izvora

Frekvencija	Prijelom	Koeficijent
Mjesečno	EURO	-0,01118 (0,01208)
Mjesečno	BATCH_NEW	0,00498 (0,01320)
Tjedno	EURO	-0,01870** (0,00925)
Tjedno	BATCH_NEW	0,00100 (0,01024)

A19 Ponuda komunikacije i pretraživanje

Vlastite HNB-ove objave i državna komunikacija mogu se mijenjati s inflacijom. Dodavanje tih varijabli provjerava osjetljivost glavnog nagiba, ali ih ne pretvara u egzogene instrumente. Google Trends standardiziran je zasebno za dio serije preuzet iz prvoga prozora i za njegov nastavak. Koristi se deskriptivno; omjeri interesa ne predstavljaju apsolutni broj pretraga.

Tablica 36: Koeficijent inflacije uz kontrole ponude komunikacije i pretraživanja

Frekvencija	Kontrola	Nagib inflacije
Mjesečno	log_hnb_comm	0,00169*** (0,00061)
Mjesečno	gov_comm_share	0,00109 (0,00078)
Mjesečno	gt_z	0,00180*** (0,00059)
Tjedno	log_hnb_comm	0,00209*** (0,00049)
Tjedno	gov_comm_share	0,00152*** (0,00050)
Tjedno	gt_z	0,00195*** (0,00048)

A20 Zajednička usporedba margina

Upareni blokovni bootstrap koristi iste rezidualne indekse za ekstenzivnu i intenzivnu jednadžbu. Prije procjene standardiziramo ishode, pa razlika koeficijenata uspoređuje njihove standardne devijacije po jedinici inflacije. Ne uspoređujemo sirove koeficijente različitih mjernih jedinica.

Tablica 37: Razlika standardiziranih koeficijenata ekstenzivne i intenzivne margine

Frekvencija	Uzorak	Razlika	Donja	Gornja
Mjesečno	S0	-0,0993	-0,2236	0,0366
Mjesečno	S1	-0,1230	-0,2624	0,0223
Mjesečno	S3	-0,2015	-1,0882	0,5951
Tjedno	S0	-0,1202	-0,1964	-0,0440
Tjedno	S1	-0,1329	-0,2234	-0,0439
Tjedno	S3	-0,3432	-0,7991	0,0937

A21 Rezidualna dijagnostika i vremenska prediktivnost

Breusch–Godfreyjev test provjerava preostalu serijsku ovisnost, Breusch–Paganov heteroskedastičnost, a Jarque–Berin normalnost. Kratki segmenti ograničavaju snagu i točnost tih testova. Dvovarijatne regresije prethodnih vrijednosti opisne su provjere Grangerove prediktivnosti, bez uzročne interpretacije.

Tablica 38: Dijagnostika reziduala modela korekcije odstupanja

Frekvencija	Uzorak	N	BG p	BP p	JB p
Mjesečno	S0	33	0,425	0,326	<0,001
Mjesečno	S3	23	0,586	0,237	0,867
Tjedno	S0	154	0,858	0,132	<0,001
Tjedno	S3	110	0,598	0,769	<0,001

Tablica 39: Dvovarijatna prediktivnost prethodnih vrijednosti po segmentima

Frekvencija	Uzorak	Smjer	Koeficijent
Mjesečno	S0	pi_to_iag	0,00101 (0,00086)
Mjesečno	S0	iag_to_pi	5,08572* (2,52930)
Mjesečno	S3	pi_to_iag	-0,00156 (0,00211)
Mjesečno	S3	iag_to_pi	10,94961 (10,09412)
Tjedno	S0	pi_to_iag	0,00137*** (0,00052)
Tjedno	S0	iag_to_pi	0,75376 (0,70993)
Tjedno	S3	pi_to_iag	0,00333 (0,00235)
Tjedno	S3	iag_to_pi	1,30282 (0,97352)

A22 Promjenjivi koeficijenti i uvjetni scenariji

Model vremenski promjenjivoga koeficijenta koristi Kalmanov postupak sa slučajnim hodom nagiba inflacije, nakon uklanjanja fiksnih kontrola. Procjenjuje se zasebno po segmentima. Izgladeni koeficijenti koriste informacije cijeloga segmenta i nisu prognoze u stvarnom vremenu. Njihove točkaste pogreške ne uključuju svu neizvjesnost procjene hiperparametara.

Uvjetni scenariji iz glavnog teksta koriste 2000 blokovnih bootstrap ponavljanja. Prikazani intervali odnose se na razliku predikcija, ne na interval budućeg pojedinačnog opažanja. Ostali regresori ostaju na opaženoj putanji, pa se scenarij ne smije tumačiti kao ukupni učinak hipotetske promjene inflacije na medijski sustav.

A23 Vremenski trendovi i godišnji čimbenici

Pozitivan zajednički nagib inflacije ne zadržava istu preciznost u svim vremenskim specifikacijama. U tjednom modelu s godišnjim indikatorima koeficijent iznosi 0,00135, uz $p = 0,172$. Mjesečni model s odvojenim trendovima segmenata također ne odbacuje nulti nagib pri uobičajenoj razini značajnosti. Zato stabilan pozitivan predznak osnovnih modela ne tumačimo kao dokaz neovisnosti nalaza o zajedničkim vremenskim čimbenicima.

Tablica 40: Zajednički nagib inflacije uz dodatne vremenske kontrole


Frekvencija	Kontrola	Koeficijent
Mjesečno	Bez dodatka	0,00175*** (0,00061)
Mjesečno	Trendovi	0,00179* (0,00103)
Mjesečno	Godine	0,00197** (0,00094)
Tjedno	Bez dodatka	0,00210*** (0,00049)
Tjedno	Trendovi	0,00250*** (0,00082)
Tjedno	Godine	0,00135 (0,00098)

Podatkovni dodatci

B1 Pokrivenost i promjena izvoza

Oznake potpunosti razlikuju tekstualnu prazninu i nepotpuno prikupljena završna razdoblja. Tjedni filter nije jednak automatskom preuzimanju mjesečnih oznaka: zadržava potpun tjedan na početku godine praznine. S2 završava u srpnju te sadrži 279 tjedana; početni broj iz plana uključivao je i potpun tjedan u kolovozu, koji je izvan toga kalendarskog prozora.

Slika 9 prikazuje brojeve objava najvećih izvora kroz vrijeme. Stabilan naziv izvora ne jamči stabilan intenzitet praćenja, a promjena broja objava može odražavati i ekonomsku aktivnost i prikupljanje podataka.



Slika 9: Mjesečni broj objava najvećih izvora oko promjene izvoza

B2 Zajednički izvori, izvorne objave i mreža

Korpus zajedničkih izvora zadržava 258 izvora s barem jednom HNB-ovom objavom u početnoj usporednoj godini i u drugoj polovici godine promjene izvoza. Isto ograničenje primjenjuje se na brojnik i inflacijski nazivnik. Njime se uklanja ulazak i izlazak naziva izvora, ali se ne izjednačava broj ili vrsta njihovih objava. Stoga ni nestanak ni preostanak indikatorskog pomaka samostalno ne dokazuje ekonomsko podrijetlo prijeloma.

Tablica 41: Pomak povezan s novim izvorom u glavnom i zajedničkom korpusu

Frekvencija	Serija	Pomak izvora
Mjesečno	IAG_primary	0,01464** (0,00659)
Mjesečno	IAG_common	0,00981 (0,00710)
Tjedno	IAG_primary	0,01619*** (0,00502)
Tjedno	IAG_common	0,01076** (0,00532)


Mrežna rekonstrukcija povezuje ocijenjene članke s tekstovima prema datumu, izvoru i URL-u, primjenjuje ista pravila aktera, čišćenja i projekcije te ponovno računa centralnost. Postoji 1242 ponovljenih ključeva teksta; pri njima se zadržava prvi zapis. Usporedba rekonstruirane neograničene mreže s panelom iz glavnog teksta pokazuje vrlo blisko podudaranje uz sačuvanu najveću apsolutnu razliku. Time provjeravamo implementaciju mreže; ta provjera sama ne osigurava usporedivost ekonomskih razina preko promjene izvoza.

Tablica 42: Uvjetni trend centralnosti među zajedničkim izvorima

Frekvencija	N	Trend zajedničke mreže
Mjesečno	25	-0,00509 (0,00371)
Tjedno	112	-0,00124* (0,00070)

B3 Promjena dobavljačeva sentimenta

Slika 10 prikazuje naglu promjenu udjela negativnih oznaka na završetku uzorka. U S2 uspoređujemo model bez sentimenta s modelom koji dopušta različit odnos sentimenta i ishoda nakon promjene dobavljačeva postupka. Kratak završni segment ne omogućuje pouzdanu procjenu novoga klasifikacijskog režima.



Slika 10: Dobavljačev udio negativnih oznaka i završna promjena postupka

Tablica 43: Osjetljivost u uzorku proširenom kroz srpanj

Frekvencija	Postupak	N	Koeficijent
Mjesečno	drop_NEG	62	0,00214*** (0,00072)
Mjesečno	interact_NEG	62	0,00175*** (0,00061)
Tjedno	drop_NEG	277	0,00238*** (0,00052)

Frekvencija	Postupak	N	Koeficijent
Tjedno	interact_NEG	277	0,00210*** (0,00049)

B4 Vanjske serije i ponovljivost

Hrvatski HICP prelazi sa serije `prc_hicp_manr` na `prc_hicp_minr` na početku završne godine. Najveća razlika usporedivih mjesečnih vrijednosti iznosi 0,1 postotnog boda. FAO-ov nominalni indeks preuzet je izravno s izvora, uz sačuvani izvorni CSV i godišnju transformaciju. Stari Eurostatov prehrambeni proxy zadržan je kao dokumentirani dio ulaznih podataka, ali nije preimenovan u stvarni FFPI.

Svi rezultati nastaju u odvojenim analitičkim skriptama. Rukopis učitava spremljene objekte i formatira njihove tablice, slike i brojke. Dostupni su manifest rezultata, kontrolni zbrojevi ulaza, zapis programskog okruženja, provjera smjera pomaka i numerička usporedba HAC kovarijance sa standardnom implementacijom na neprekinutom segmentu. Izvorni rukopis i njegovi nacrti nisu mijenjani. Puni rezultati specifikacija, simulacija i lokalnih projekcija dostupni su u popratnim strojno čitljivim tablicama. Popratni dodatak donosi usporedbu sa zamrznutim tablicama starog rada, statičke modele očekivanja, projekcije primarnog jaza, interakcije s režimom te dodatne provjere platformi i sentimenta.

Literatura

Bracha, A., i Tang, J. (2019). *Inflation Thresholds and Inattention*. (br. 19-14) Federal Reserve Bank of Boston. <https://doi.org/10.29412/res.wp.2019.14>.

Coibion, O., Gorodnichenko, Y., i Weber, M. (2022). Monetary Policy Communications and Their Effects on Household Inflation Expectations. *Journal of Political Economy*, 130(6), 1537–1584. <https://doi.org/10.1086/718982>.

Entman, R. M. (1993). Framing: Toward Clarification of a Fractured Paradigm. *Journal of Communication*, 43(4), 51–58.

Food and Agriculture Organization of the United Nations. (2026). FAO Food Price Index. <https://www.fao.org/worldfoodsituation/foodpricesindex/en/>.

Jordà, Ò. (2005). Estimation and Inference of Impulse Responses by Local Projections. *American Economic Review*, 95(1), 161–182. <https://doi.org/10.1257/0002828053828518>.

Malmendier, U., i Nagel, S. (2016). Learning from Inflation Experiences. *The Quarterly Journal of Economics*, 131(1), 53–87. <https://doi.org/10.1093/qje/qjv037>.

Mankiw, N. G., i Reis, R. (2002). Sticky Information Versus Sticky Prices: A Proposal to Replace the New Keynesian Phillips Curve. *Quarterly Journal of Economics*, 117(4), 1295–1328.

Newey, W. K., i West, K. D. (1987). A Simple, Positive Semi-Definite, Heteroskedasticity and Autocorrelation Consistent Covariance Matrix. *Econometrica*, 55(3), 703–708. <https://www.nber.org/papers/t0055>.

Oster, E. (2019). Unobservable Selection and Coefficient Stability: Theory and Evidence. *Journal of Business and Economic Statistics*, 37(2), 187–204.

Pesaran, M. H., Shin, Y., i Smith, R. J. (2001). Bounds Testing Approaches to the Analysis of Level Relationships. *Journal of Applied Econometrics*, 16(3), 289–326.

Pfäuti, O. (2023). The Inflation Attention Threshold and Inflation Surges. <https://arxiv.org/abs/2308.09480>.

Shoemaker, P. J., i Vos, T. P. (2009). *Gatekeeping Theory*. Routledge.

Sims, C. A. (2003). Implications of Rational Inattention. *Journal of Monetary Economics*, 50(3), 665–690.

Woodford, M. (2003). *Interest and Prices: Foundations of a Theory of Monetary Policy*. Princeton University Press.